






- 순차적인 데이터(sequential data)를 학습하여 분류 또는 예측을 수행
  - Recurrent Neural Networks have loops.
- 각 레이어마다 파라미터(Parameter)들이 독립적이었으나 RNN은 공유.
- 과거의 데이터가 미래에 영향을 줄 수 있는 구조
- 응용
  - 음성, 자연어 문장, 동영상, 주가 변동등의 시계열(time series)데이터를 분석하여 분류 및 예측
  - 자율주행 시스템에서 차의 이동 경로를 예측
  - 문장, 문서, 오디오 샘플을 입력 받을 수 있고, 자동번역, 스피치 투 텍스트같은 자연 어 처리에 매우 유용
  - 기계번역, 음성 인식, 필기체 인식, 영상 주석달기, 동영상에서 행동인식, 작곡 및 작사 등 다양한 응용분야에서 활용






ref: python machine learning 2nd Ed




- **one to one**: from fixed-sized input to fixed-sized output(Vanilla mode)
  - e.g. image classification
- one to many: sequence output
  - e.g. image captioning takes an image and outputs a sentence of words
- many to one : sequence input
  - e.g. sentiment analysis where a given sentence is classified as expressing positive or negative sentiment
- **many to many**: sequence input and sequence output
  - e.g. machine translation: an RNN reads a sentence in English and then outputs a sentence in French
- many to many: synced sequence input and output
  - e.g. video classification where we wish to label each frame of the video



red: input vectors, blue: output vectors, green: RNN's state


## **Example: one to many**


- CNN과 RNN 조합
- *image captioning(one to many)*



## Recurrent Neural Network


We can process a sequence of vectors **x** by applying a **recurrence formula** at every time step:





# (Simple) Recurrent Neural Network

The state consists of a single "hidden" vector h:




$$h_t = f_W(h_{t-1}, x_t)$$

$$h_t = anh(W_{hh}h_{t-1} + W_{xh}x_t)$$


$$y_t = W_{hy} h_t$$

Sometimes called a <u>"Vanilla RNN"</u> or an <u>"Elman RNN"</u> after Prof. Jeffrey Elman



A recurrent neural network and the unfolding in time of the computation involved in its forward computation. Source: Nature

- $x_t : t$ 에서의 입력 값
- $h_t$ : t에서의  $hidden\ state$ . 네트워크의 메모리(과거 시간 스텝들에서 일어난 정보).
  - -t-1의 hidden state 값과 현재 t의 입력값( $x_t$ )에 의해 계산.
  - $h_t = tanh(Ux_t + Ws_{t-1})$
  - 최초(s<sub>−1</sub>)는 0으로 초기화
- $y_t$ : t에서의 출력 값. 현재시간 t의 메모리만 의존
  - $y_t = softmax(Vh_t)$
- 모든 시간 스텝에 대해 파라미터 값 공유 (U,V,W)



$$h_t = f_W(h_{t-1}, x_t) \ dots \ h_t = anh(W_{hh}h_{t-1} + W_{xh}x_t) \ y_t = W_{hy}h_t$$


$$fw_h^t = W_{xh}x^t + W_{hh}h^{t-1} + b_h$$

$$h^t = \phi_h(fw_h^t) = \phi_h(W_{xh}x^t + W_{hh}h^{t-1} + b_h)$$

$$W_h = [W_{xh}; W_{hh}]$$

$$h^t = \phi_h([W_{xh}; W_{hh}] \begin{bmatrix} x^t \\ h^{t-1} \end{bmatrix} + b_h)$$

$$y^t = \phi_y(W_{hy}h^t + b_y)$$




• m개의 단어로 이루어져 있는 문장이 있다면 특정데이터셋에서 이 문장이 나타 날 확률

$$P(w_1, \dots, w_m) = \prod_{i=1}^m P(w_i | w_1, \dots, w_{i-1})$$


(Ex) He went to buy some chocolate의 문장 확률은?

- He went to buy some 주어졌을 때 chocolate 확률 곱하기
- He went to buy 주어졌을 때 some 확률 곱하기
- 문장의 시작 He의 확률까지의 곱
- 단어들의 확률은 이전에 나왔던 모든 단어들에 의존
- 하지만 실제 구현에서는 많은 모델들이 계산량, 메모리 문제 등으로 인해 longterm dependency를 효과적으로 다루지 못해서 긴 시퀀스는 처리하는 것이 힘 들다.




- RNN 모델을 학습하는데 사용되는 핵심 알고리즘
- 전체 손실(E): t = 1에서 t = T까지 타임 스텝의 모든 손실함수 합

$$L = \sum_{t=1}^{L} L^{t}$$
 
$$\frac{\delta L_{3}}{\delta V} = \frac{\delta L_{3}}{\delta \hat{y}_{3}} \frac{\delta \hat{y}_{3}}{\delta V} = \frac{\delta L_{3}}{\delta \hat{y}_{3}} \frac{\delta \hat{y}_{3}}{\delta z_{3}} \frac{\delta z_{3}}{\delta V} = (\hat{y}_{3} - y_{3}) \otimes s_{3}$$
 
$$z_{3} = V h_{3}, \qquad \otimes :$$
 두 벡터의 외적



$$\frac{\delta L_3}{\delta W} = \frac{\delta L_3}{\delta \hat{y}_3} \frac{\delta \hat{y}_3}{\delta h_3} \frac{\delta h_3}{\delta W}$$

$$\begin{split} h_t &= tanh(Ux_t + Wh_{t-1}): h_3 \vdash h_2 \text{에 의존}, h_2 \vdash h_1 \text{에 의존} \\ \frac{\delta L_3}{\delta W} &= \sum_{t=1}^3 \frac{\delta L_3}{\delta \hat{y}_3} \frac{\delta \hat{y}_3}{\delta h_3} \frac{\delta h_3}{\delta h_k} \frac{\delta h_k}{\delta W} \end{split}$$



타임 스텝 t에서 손실은 모든 이전 타임 스텝 1: t-1의 유닛에 의존


$$\frac{\delta L_t}{\delta W} = \frac{\delta L_t}{\delta \hat{y}_t} \times \frac{\delta \hat{y}_t}{\delta h_t} \times \left( \sum_{k=1}^t \frac{\delta h_t}{\delta h_k} \times \frac{\delta h_k}{\delta W} \right), \qquad \frac{\delta h^t}{\delta h_k} = \prod_{i=k+1}^t \frac{\delta h_i}{\delta h_{i-1}}$$

 $\frac{\delta h^t}{\delta h^k}$ (이전타임스텝의곱)로 인하여 $vanishing\ gradient$ 발생  $\frac{\delta h^t}{\delta h^k}$ 는k개의 곱셈.즉,가중치w가t-k번 곱해져서  $w^{t-1}$ 이 된다

|w| < 1이면 t - k가 클 때  $w^{t-k}$  값이 매우 작아진다.


|w| > 1이면 t - k 가 클 때  $w^{t-k}$  값이 매우 커진다

t - k 크다는 것은 긴 시간 의존성을 가진다는 의미. 해결책 : |w| = 1







- RNN의 Gradient Problem 해결책
  - $T-BPTT(Truncated\ BackPropagation\ Through\ time)$
  - LSTM(Long Short Term Memory)
- LSTM의 중요요소 : 메모리 셀(memory cell) 은닉층
  - 각 메모리 셀에 적절한 가중치 w=1를 유지하는 게이트
    - cell state: 게이트의 출력
  - 저장할 것, 버릴 것, 읽어 들일 것을 학습하는 것
  - $h_t$ : 단기상태(short term state)
  - $-c_t$ : 장기상태(long term state)
  - $-y_t$ : 출력



- 이전 타임 스텝의 셀 상태 $(c_{t-1})$   $\frac{1}{(r) \odot (r) \odot (r) \odot (r)}$  현재 타임 스텝 셀 상태  $(c_t)$  생성
  - 네트워크를 왼쪽에서 오른쪽을 관통하면서 삭제 게이트를 지나 일부 기억을 잃고,
  - 이후 덧셈 연산으로 새로운 기억(입력 게이트에서 선택한 기억)일부를 추가
  - 그래서 타입 스텝마다 일부 기억이 삭제되고 일부 기억이 추가된다
- 덧셈 연산 후 장기 상태 $(c_t)$ 가 복사되어 tanh 함수로 전달
  - 이 결과는 출력 게이트에 의해 걸러진 후 단기상태 $(h_t)$ 와 출력 $(y_t)$ 을 만든다.



- 주층 :  $g_t$ 
  - 현재 입력  $x_i$ 와 이전의 상태 (단기상태,  $h_{t-1}$ )을 분석하는 역할
  - 이 층의 출력이 곧 바로 나가지 않고 장기 상태에서 가장 중요한 부분은 저장하고 나 머지는 삭제(기본 셀에서는  $y_t$ ,  $h_t$ 로 출력)
- 게이트 제어기(gate controller) :  $f_t$ ,  $i_t$ ,  $o_t$ 
  - 시그모이드 함수( $\sigma$ ) 사용
  - 출력은 원소 별 곱셈 연산(⊗) 수행 : gate라 한다
    - 0을 출력하면 게이트를 닫고 1을 출력하면 게이트를 연다
  - 삭제(forget) 게이트( $f_t$ )
    - 장기상태의 어느 부분이 삭제되어야 하는 지 제어
    - 통과할 정보와 억제할 정보 결정
  - 입력(input) 게이트( $i_t$ )
    - $g_t$ 의 어느 부분이 장기 상태에 더해져야 하는지 제어
  - 출력(ouput) 게이트( $o_t$ )
    - 장기 상태의 어느 부분을 읽어서  $h_t$ 와  $y_t$ 로 출력해야 하는지 제어



$$g_t = tanh(W_{xg} \cdot x_t + W_{hg} \cdot h_{t-1} + b_g)$$

$$f_t = \sigma(W_{xf}^T \cdot x_t + W_{hf}^T \cdot h_{t-1} + b_f)$$


$$i_t = \sigma(W_{xi}^T \cdot x_t + W_{hi}^T \cdot h_{t-1} + b_f)$$

$$o_t = \sigma(W_{xo}^T \cdot x_t + W_{ho}^T \cdot h_{t-1} + b_o)$$

$$\mathbf{c_t} = \mathbf{f_t} \otimes \mathbf{c_{t-1}} + \mathbf{i_t} \otimes \mathbf{g_t}$$

$$y_t = h_t = o_t \otimes tanh(c_t)$$

- $W_{xf}$ ,  $W_{xi}$ ,  $W_{xg}$ ,  $W_{xo}$ 입력벡터  $x_t$ 에 연결된 가중치 행렬
- $W_{hf}$ ,  $W_{hi}$ ,  $W_{hg}$ ,  $W_{ho}$ 이전 스텝의 단기 상태 $(h_{t-1})$ 에 연결된 가 중치 행렬



## **LSTM Backpropagation**

$$\delta h_{t} = \Delta_{t} + \Delta h_{t}$$

$$\delta c_{t} = \delta h_{t} \otimes o_{t} \otimes (1 - tanh^{2}(c_{t})) + \delta c_{t+1} \otimes f_{t+1}$$

$$\delta g_{t} = \delta c_{t} \otimes i_{t} \otimes (1 - g_{t}^{2})$$

$$\delta f_{t} = \delta c_{t} \otimes c_{t-1} \otimes f_{t} \otimes (1 - f_{t})$$

$$\delta i_{t} = \delta c_{t} \otimes g_{t} \otimes i_{t} \otimes (1 - i_{t})$$

$$\delta o_{t} = \delta h_{t} \otimes tanh(c_{t}) \otimes o_{t} \otimes (1 - o_{t})$$

$$\delta x_{t} = W_{x}^{T} \cdot \delta gates_{t}$$

$$\Delta h_{t-1} = W_{h}^{T} \cdot \delta gates_{t}$$

The final updates to the internal parameters is computed as:

$$\delta W_{x} = \sum_{t=0}^{n} \delta gate_{t} \otimes x_{t}$$

$$\delta W_{h} = \sum_{t=0}^{n} \delta gate_{t+1} \otimes h_{t}$$

$$\delta b = \sum_{t=0}^{n} \delta gate_{t+1}$$

## The Example

#### weight:

$$W_{xg} = \begin{bmatrix} 0.45 \\ 0.25 \end{bmatrix}, \qquad W_{hg} = [0.15], \qquad b_g[0.2]$$
 $W_{xf} = \begin{bmatrix} 0.7 \\ 0.45 \end{bmatrix}, \qquad W_{hf} = [0.1], \qquad b_f[0.15]$ 
 $W_{xi} = \begin{bmatrix} 0.95 \\ 0.8 \end{bmatrix}, \qquad W_{hi} = [0.8], \qquad b_i[0.65]$ 
 $W_{xo} = \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}, \qquad W_{ho} = [0.25], \qquad b_o[0.1]$ 

#### input data:

$$x_0 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$
 with label: 0.5

$$x_1 = \begin{bmatrix} 0.5 \\ 3 \end{bmatrix}$$
 with label: 1.25

$$g_{0} = tanh(W_{xg} \cdot x_{0} + W_{hg} \cdot h_{-1} + b_{g})$$

$$= tanh([0.45 \quad 0.25] \begin{bmatrix} 1\\2 \end{bmatrix} + [0.15][0] + [0.2]) = 0.81775$$

$$f_{0} = \sigma(W_{xf}^{T} \cdot x_{0} + W_{hf}^{T} \cdot h_{-1} + b_{f})$$

$$= \sigma([0.7 \quad 0.45] \begin{bmatrix} 1\\2 \end{bmatrix} + [0.1][0] + [0.15]) = 0.85195$$

$$i_{0} = \sigma(W_{xi}^{T} \cdot x_{0} + W_{hi}^{T} \cdot h_{-1} + b_{f})$$


$$= \sigma([0.95 \quad 0.8] \begin{bmatrix} 1\\2 \end{bmatrix} + [0.8][0] + [0.65]) = 0.96083$$

$$o_{0} = \sigma(W_{xo}^{T} \cdot x_{0} + W_{ho}^{T} \cdot h_{-1} + b_{o})$$

$$= \sigma([0.6 \quad 0.4] \begin{bmatrix} 1\\2 \end{bmatrix} + [0.25][0] + [0.1]) = 0.81757$$

$$c_{0} = f_{0} \otimes c_{0-1} + i_{0} \otimes g_{0} = 0.85195 \times 0 + 0.96083 \times 0.81775 = 0.78572$$

$$y_{0} = h_{0} = o_{0} \otimes tanh(c_{0}) = 0.81757 \times tanh(0.78572) = 0.53631$$



$$g_{1} = tanh(W_{xg} \cdot x_{1} + W_{hg} \cdot h_{0} + b_{g})$$

$$= tanh([0.45 \quad 0.25] \begin{bmatrix} 0.5 \\ 3 \end{bmatrix} + [0.15][0.53631] + [0.2]) = 0.84980$$

$$f_{1} = \sigma(W_{xf}^{T} \cdot x_{1} + W_{hf}^{T} \cdot h_{0} + b_{f})$$

$$= \sigma([0.7 \quad 0.45] \begin{bmatrix} 0.5 \\ 3 \end{bmatrix} + [0.1][0.53631] + [0.15]) = 0.87030$$

$$i_{1} = \sigma(W_{xi}^{T} \cdot x_{1} + W_{hi}^{T} \cdot h_{0} + b_{f})$$


$$= \sigma([0.95 \quad 0.8] \begin{bmatrix} 0.5 \\ 3 \end{bmatrix} + [0.8][0.53631] + [0.65]) = 0.98118$$

$$o_{1} = \sigma(W_{xo}^{T} \cdot x_{1} + W_{ho}^{T} \cdot h_{0} + b_{o})$$

$$= \sigma([0.6 \quad 0.4] \begin{bmatrix} 0.5 \\ 3 \end{bmatrix} + [0.25][0.53631] + [0.1]) = 0.84993$$

$$c_{1} = f_{1} \otimes c_{0} + i_{1} \otimes g_{1} = 0.87030 \times 0.78572 + 0.98118 \times 0.84980 = 1.5176$$


$$y_{1} = h_{1} = o_{1} \otimes tanh(c_{1}) = 0.84993 \times tanh(1.5176) = 0.77197$$



#### Backward @t=1

$$\begin{split} E(\hat{y},y) &= \frac{(\hat{y}-y)^2}{2} \\ \delta_x E(\hat{y},y) &= \hat{y}-y \\ \Delta_1 &= \delta_y E = 0.77197 - 1.25 = -0.47803 \\ \Delta h_1 &= 0 \ (no \ next \ time \ steps) \\ \end{split}$$
 
$$\begin{split} \delta h_1 &= \Delta_1 + \Delta h_1 = -0.47803 + 0 = -0.47803 \\ \delta c_1 &= \delta h_1 \otimes o_1 \otimes (1 - tanh^2(c_1)) + \delta c_2 \otimes f_2 \\ &= -0.47803 \times 0.84993 \times (1 - tanh^2(1.5176)) + 0 \times 0 = -0.07111 \\ \delta g_1 &= \delta c_1 \otimes i_1 \otimes (1 - g_1^2) = -0.07111 \times 0.98118 \times (1 - 0.84980^2) = -0.01938 \\ \delta f_1 &= \delta c_1 \otimes c_0 \otimes f_1 \otimes (1 - f_1) = -0.07111 \times 0.0.78572 \times 0.87030 \times (1 - 0.87030) = -0.00631 \\ \delta i_1 &= \delta c_1 \otimes g_1 \otimes i_1 \otimes (1 - i_1) = -0.07111 \times 0.84980 \times 0.98118 \times (1 - 0.98118) = -0.00112 \\ \delta o_1 &= \delta h_1 \otimes tanh(c_1) \otimes o_1 \otimes (1 - o_1) \\ &= -0.47803 \times tanh(1.5176) \times 0.84993 \times (1 - 0.84993) = -0.05538 \\ \delta x_1 &= W_x^T \cdot \delta gates_1 = \begin{bmatrix} 0.45 & 0.70 & 0.95 & 0.60 \\ 0.25 & 0.45 & 0.80 & 0.40 \end{bmatrix} \begin{bmatrix} -0.01938 \\ -0.00631 \\ -0.00538 \end{bmatrix} = \begin{bmatrix} -0.04743 \\ -0.03073 \end{bmatrix} \\ \Delta h_0 &= W_h^T \cdot \delta gates_1 = \begin{bmatrix} 0.45 & 0.70 & 0.95 & 0.60 \\ 0.25 & 0.45 & 0.80 & 0.40 \end{bmatrix} \begin{bmatrix} -0.01938 \\ -0.00631 \\ -0.00538 \end{bmatrix} = -0.01828 \\ \end{bmatrix} = -0.01828 \end{split}$$


## Backward @t = 1



#### Backward @t=0

$$\begin{split} E(\hat{y},y) &= \frac{(\hat{y}-y)^2}{2} \\ \delta_x E(\hat{y},y) &= \hat{y} - y \\ \Delta_0 &= \delta_x E = 0.53631 - 0.5 = 0.03631 \\ \Delta h_0 &= -0.01828 \ (passed \ back \ from \ t = 1) \\ \delta h_0 &= \Delta_0 + \Delta h_0 = 0.03631 + -0.01828 = 0.01803 \\ \delta c_0 &= \delta h_0 \otimes o_0 \otimes \left(1 - tanh^2(c_0)\right) + \delta c_1 \otimes f_1 \\ &= 0.01803 \times 0.81757 \times \left(1 - tanh^2(0.78572)\right) \pm 0.07111 \times 0.87030 = -0.05349 \\ \delta g_0 &= \delta c_0 \otimes i_0 \otimes \left(1 - g_0^2\right) = -0.05349 \times 0.996083 \times \left(1 - 0.81775^2\right) = -0.01703 \\ \delta f_0 &= \delta c_0 \otimes c_{-1} \otimes f_0 \otimes \left(1 - f_0\right) = -0.05349 \times 0.85195 \times \left(1 - 0.85195\right) = 0 \\ \delta i_0 &= \delta c_0 \otimes g_0 \otimes i_0 \otimes \left(1 - i_0\right) = -0.05349 \times 0.81775 \times 0.96083 \times \left(1 - 0.96083\right) = -0.00165 \\ \delta o_0 &= \delta h_0 \otimes tanh(c_0) \otimes o_0 \otimes \left(1 - o_0\right) \\ &= -0.01803 \times tanh(0.78572) \times 0.81757 \times \left(1 - 0.81757\right) = -0.00176 \\ \delta x_0 &= W_x^T \cdot \delta gates_0 = \begin{bmatrix} 0.45 & 0.70 & 0.95 & 0.60 \\ 0.25 & 0.45 & 0.80 & 0.40 \end{bmatrix} \begin{bmatrix} -0.01703 \\ 0 \\ -0.00165 \\ -0.00176 \end{bmatrix} = \begin{bmatrix} -0.00817 \\ -0.00487 \end{bmatrix} \\ \Delta h_{-1} &= W_h^T \cdot \delta gates_0 = \begin{bmatrix} 0.15 & 0.10 & 0.80 & 0.25 \end{bmatrix} \begin{bmatrix} -0.01703 \\ 0 \\ -0.00165 \\ -0.00165 \end{bmatrix} = -0.00343 \\ 0 -0.00165 \\ 0 -0.00165 \end{bmatrix} = -0.00343 \end{split}$$

## Backward @t = 0



## **LSTM Backpropagation**

$$\delta W_x = \sum_{t=0}^n \delta gate_t \otimes x_t = \begin{bmatrix} -0.01703 \\ 0 \\ -0.00165 \\ -0.00176 \end{bmatrix} [1.0 \quad 2.0] + \begin{bmatrix} -0.01938 \\ -0.00631 \\ -0.05538 \end{bmatrix} [0.5 \quad 3.0] = \begin{bmatrix} -0.02672 & -0.09220 \\ -0.00316 & -0.01893 \\ -0.00221 & -0.00666 \\ -0.02593 & -0.16262 \end{bmatrix}$$


$$\delta W_h = \sum_{t=0}^{n} \delta gate_{t+1} \otimes h_t = \begin{bmatrix} -0.01938 \\ -0.00631 \\ -0.00112 \\ -0.05538 \end{bmatrix} [0.53631] = \begin{bmatrix} -0.01039 \\ -0.00338 \\ -0.00060 \\ -0.02970 \end{bmatrix}$$

$$\delta b = \sum_{t=0}^{n} \delta gate_{t+1} = \begin{bmatrix} -0.01703 \\ 0 \\ -0.00165 \\ -0.00176 \end{bmatrix} + \begin{bmatrix} -0.01938 \\ -0.00631 \\ -0.00112 \\ -0.05538 \end{bmatrix} = \begin{bmatrix} -0.03641 \\ -0.00631 \\ -0.00277 \\ -0.05714 \end{bmatrix}$$

Updating out parameters based on the SGD update function  $(\lambda = 0.1)$ :  $W^{new} = W^{old} - \lambda \delta W^{old}$ 


$$W_{xg} = \begin{bmatrix} 0.45267 \\ 0.25922 \end{bmatrix}, \qquad W_{hg} = [0.15104], \qquad b_g = [0.20364]$$
 $W_{xf} = \begin{bmatrix} 0.70032 \\ 0.45189 \end{bmatrix}, \qquad W_{hf} = [0.10034], \qquad b_f = [0.15063]$ 
 $W_{xi} = \begin{bmatrix} 0.95022 \\ 0.80067 \end{bmatrix}, \qquad W_{hi} = [0.80006], \qquad b_i = [0.65027]$ 
 $W_{xo} = \begin{bmatrix} 0.60259 \\ 0.41626 \end{bmatrix}, \qquad W_{ho} = [0.25297], \qquad b_o = [0.10536]$ 

- 2014년에 K. Cho(조경현) 등에 의해 제안된 LSTM의 간소화된 버전
  - Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation



- LSTM의  $c_t$ 와  $h_t$ 가 하나의 벡터  $h_t$ 로 합쳐졌다.
- 하나의 gate controller인  $z_t$ 가 forget과 input 게이트를 제어한다.
  - $-z_t$ 가 1을 출력하면 forget 게이트가 열리고 input 게이트가 닫힌다.
  - $-z_t$ 가 0을 출력하면 forget 게이트가 닫히고 input 게이트가 열린다.
  - 즉, 이전(t-1)의 기억이 저장될 때 마다 타임스텝 t의 입력은 삭제된다.
- GRU는 output 게이트가 없어 전체 상태 벡터  $h_t$ 가 타임스텝마다 출력되며,
- 이전 상태 $(h_{t-1})$ 의 어느 부분이 출력될지 제어하는 새로운 gate controller인  $r_t$ 가 있다.

## **Recurrent Neural Network**



**Convolutional Neural Network** 

image

conv-64

conv-64

maxpool

conv-128

conv-128

maxpool

conv-256

conv-256

maxpool

conv-512

conv-512

maxpool

conv-512

conv-512

maxpool

FC-4096

FC-4096

FC-1000

softmax



test image

image

conv-64

conv-64

maxpool

conv-128

conv-128

maxpool

conv-256

conv-256

maxpool

conv-512

conv-512

maxpool

conv-512

conv-512

maxpool

FC-4096

FC-4096



test image



